

TRABAJO FIN DE MÁSTER

Análisis de textos médicos mediante NLP

Autor:

Jesús Enrique Cartas Rascón

Profesor:

Rocío Romero Zaliz

Resumen

En el ámbito de la medicina se almacena una gran cantidad de información relevante: desde valores numéricos correspondientes a signos vitales hasta texto plano que realiza un especialista para completar un informe. Muchas veces los datos guardados en el historial médico de un paciente, que no tiene una estructura determinada, son ignorados. Este proyecto propone recuperar texto médico sin formato para extraer nuevo conocimiento que pueda utilizarse para complementar la información estructurada y mejorar en la clasificación y tratamiento de los pacientes.

ÍNDICE GENERAL

1. Introducción	3
1.1. Texto sin formato	3
1.2. Falta de datos	3
1.3. Objetivos	3
2. Fundamentos de la minería de texto	5
2.1. Minería de datos	5
2.2. Minería de texto	6
2.2.1. Términos	6
2.2.2. Técnicas	9
Bibliografía	15

1. INTRODUCCIÓN

En este capítulo introduciremos los principales problemas existentes en el contexto de minería de datos en el texto médico y proponemos una solución que se desarrollará a lo largo del documento.

1.1. Texto sin formato

Toda atención médica dispone de documentos que recogen toda la información relacionada con el paciente, enfermedad, y un seguimiento de ambos, así como los recursos a utilizar. En estos documentos suele haber una sección en la que el o la profesional en cuestión describe, en lo que podríamos denominar *texto sin formato* todas estas factores. Debido a la carencia de formato, es difícil trabajar con dichas secciones, por lo que se suelen ignorar.

La idea es centrar nuestra atención en esas secciones de texto, con objeto de obtener la mayor cantidad de información posible y anexarla, ahora con formato, al documento del que provienen, enriqueciendo el informe y habilitando nuevas claves de búsqueda, así como mejorando el indexado de los documentos.

1.2. Falta de datos

Uno de los principales problemas a los que nos enfrentamos es la falta de *datasets* o conjuntos de datos en los que estos documentos estén presentes.

Se buscarán y agregarán tantas fuentes de datos como sea posible, se unificarán y se creará una herramienta que aproveche todos los datos disponibles públicamente para generar datos nuevos.

1.3. Objetivos

Dado este marco, describiremos en esta sección los objetivos de nuestro trabajo.

En primer lugar, se agregarán todas las fuentes de información públicas que nos provean con datos de comentarios médicos listos para su minería y análisis.

Utilizando todos estos datos, se hará una evaluación de las herramientas que ya existen en el estado del arte. Haremos una revisión de cómo se utilizan y del rendimiento de dichas herramientas.

Sin embargo, para evaluar dichas herramientas, no utilizaremos los datos encontrados, sino que efectuaremos un flujo de trabajo alternativo. Utilizando técnicas de aprendizaje automático y generativo, crearemos un modelo que sea capaz de generar tantos comentarios médicos como sea necesario. La idea es suplir la carencia de datos con un modelo generativo, de forma que no se tenga que lidiar con aspectos de privacidad o licencia, ya que todos los comentarios serían generados de forma sintética.

Si bien los comentarios son sintéticos, deben ser lo suficientemente convincentes como para que la evaluación de las herramientas sea fiel y rigurosa. Esto ofrece una herramienta para los desarrolladores de las herramientas que habilita a un mejor y más fructífero desarrollo, ya que se dispone de una cantidad, *idealmente infinita* de comentarios.

2. FUNDAMENTOS DE LA MINERÍA DE TEXTO

En este capítulo discutiremos algunas de las técnicas y términos más importantes a la hora de hablar de minería de texto, así como minería de datos en general, con objeto de que todas las consideraciones realizadas posteriormente queden claras.

En *Text Mining Applied to Electronic Medical Records: A Literature Review* [1] se hace una revisión de los diferentes aspectos a tener en cuenta durante el procesamiento de textos médicos. Nos apoyaremos en gran medida en la estructura, contenidos y referencias de este artículo, que resume muy bien todo lo que necesitamos saber para resolver nuestro problema.

2.1. Minería de datos

La minería de datos es una rama de la informática que se dedica a encontrar tendencias y patrones en grandes volúmenes de información. Estas tendencias y patrones crean *conocimiento* a partir de los datos, es decir: información estructurada desde los datos no estructurados. Esta información es muy valiosa y contribuye en las decisiones que se vayan a tomar o a monitorizar algunos aspectos que sean de vital importancia para el interesado.

La minería de datos puede dividirse en un número de técnicas que funcionan de forma diferente en función del tipo de datos que tengamos y la información que busquemos.

1. **Asociación:** esta técnica se centra en encontrar relaciones entre las distintas variables de nuestros datos, con objeto de encontrar muestras que sean estadísticamente dependientes. Una de las técnicas más utilizadas son las reglas de asociación, cuya salida tras el cálculo son un conjunto de reglas con antecedentes y consecuentes, muy fácilmente interpretables por cualquier persona, familiarizada o no con la ciencia de datos. [2]
2. **Clasificación:** el proceso de clasificación trata de asignar una categoría a un conjunto de elementos que tengan algún aspecto en común. La clasificación en la minería

de datos es una de las técnicas más utilizadas, ya que la naturaleza de gran parte de los datos responden bien a este método. [3]

3. **Agrupamiento:** también denominado *clustering* trata de agrupar muestras que tengan características similares. A diferencia de la clasificación, aquí no tenemos una etiqueta o categoría a la que asignar las muestras, sino que las agrupamos *a ciegas*, simplemente basándonos en alguna métrica para evaluar la distancia que haya entre un determinado par de muestras. [4]
4. **Predicción:** la predicción nos ayuda a encontrar tendencias entre variables, generalmente en datos con una componente temporal fuerte. [5] Es común poder predecir si un paciente sufrirá una determinada enfermedad conociendo su historial médico, por ejemplo.
5. **Identificación de patrones secuenciales:** Al igual que la predicción, se trabaja sobre datos con una componente temporal marcada. En este caso, se buscan patrones, es decir, conjuntos o cadenas de muestras que aparecen de forma frecuente en un orden concreto.

2.2. Minería de texto

En esta sección, discutiremos los diferentes aspectos a tener en cuenta en la minería de textos en concreto, tras haber abordado el concepto de minería de datos en un ámbito más general.

2.2.1. Términos

Definiremos algunos de los términos más utilizados en esta disciplina, guiándonos principalmente por el trabajo de Kamran Kowsari, *Text Classification Algorithms: A Survey* [6].

Tokens

El término más esencial en minería de textos es *token*. Un token es la mínima unidad en la que dividiremos un cuerpo de texto a la hora de analizarlo. Este elemento suele corresponderse con una palabra, que en el contexto de la mayoría de los idiomas corresponde con un conjunto de letras separado por espacios anterior y posteriormente. Esto da lugar a la creación de *Tokenizers*, algoritmos que toman un cuerpo de texto como una

cadena de caracteres muy larga, y devuelven un vector de palabras. Estos *tokenizers* no han de tomar el espacio en blanco necesariamente ni exclusivamente como criterio divisor, aunque suele ser lo más común. Algunos de los *tokenizers* más famosos son:

- **Tokenizers de palabras**

- **Standard Tokenizer:** El Standard Tokenizer divide el texto en términos siguiendo los límites de las palabras según están definidos en el algoritmo *Unicode Text Segmentation*. Funciona bien en general.
- **Letter Tokenizer:** divide el texto en términos cada vez que encuentra un carácter que no es una letra.
- **Whitespace Tokenizer:** Toma como criterio divisor el espacio en blanco.
- **Language Tokenizer:** Otros tipos de tokenizers adaptados a diferentes idiomas, como el inglés, que es el idioma más estudiado con diferencia, pero también otros idiomas con caracteres y reglas diferentes a aquellos basados en reglas occidentales, como el tailandés, o el chino.

- **Tokenizers de palabras parciales**

- **N-Gram Tokenizer:** Este tokenizador incluye un parámetro adicional. Primero divide el texto con alguna de las reglas mencionadas anteriormente, y posteriormente, divide cada término del vector resultante en una ventana deslizable de n elementos, de ahí *N-Gram*. Por ejemplo: *quick fox* devolvería [qu, ui, ic, ck], [fo, ox], dado un $n = 2$. Estos tokenizers también pueden utilizarse a nivel de párrafo, por lo que se devolverían pares de palabras, algo que puede ser muy útil para el análisis de *dichos* o expresiones.

- **Tokenizers de texto estructurado**

- **Pattern Tokenizer:** este tokenizer utiliza el patrón provisto como parámetro para la división de texto, utilizando expresiones regulares.
- **Simple Pattern Tokenizer:** este tokenizer utiliza el patrón provisto como parámetro para la división de texto, utilizando expresiones optimizadas para el patrón dado, lo que hace que funcione generalmente más rápido pero también será más específico.

En resumen, un tokenizer es un algoritmo que divide el texto provisto siguiendo los criterios definidos por el usuario, devolviendo un vector con los elementos del texto divididos atendiendo a dichos criterios. Es una de las herramientas más esenciales en la minería de texto, ya que permite generar la mínima unidad de información a partir de la que se extraerá conocimiento.

Palabras vacías

Las palabras vacías o *stopwords* son términos presentes en un idioma que sirven de apoyo para la formulación de oraciones pero que no poseen información en sí. Nos referimos a los artículos, determinantes, preposiciones, etc.

Estos términos son considerados como *ruido* en el procesamiento de texto, por lo que lo más usual es disponer de un diccionario de términos vacíos y filtrar el texto original, eliminando dichos términos. De esta forma, nos quedamos con las palabras más importantes. Los símbolos de puntuación también se suelen considerar como ruido; si bien son esenciales para la comprensión y estructuración de texto para los humanos, suponen un detrimento para algoritmos de clasificación.

Sin embargo, esta operación es delicada y no siempre ofrecerá buenos resultados. Por ejemplo, si tratamos de inferir la intención de la oración *No me gusta el fútbol* y pasamos previamente un filtro de palabras vacías, el texto resultante sería *gusta fútbol*. Dados estos términos, se infiere que se está opinando de forma positiva acerca del tema *fútbol*, cuando no es así.

Este caso particular está descrito en la literatura como *negation handling*, en trabajos como [7] o [8]. Aún así, hay muchos factores que se deben tener en cuenta antes de eliminar términos de una oración.

Stemming y Lematización

Stemming hace referencia a la gestión de palabras con prefijos o sufijos para su integración en una frase, como plurales (casa, casas). Se trata de eliminar los posibles complementos añadidos con objeto de normalizar las palabras y que todas tengan la misma forma. En este caso también han de tenerse en cuenta las negaciones (típico, atípico).

La lematización va un paso más allá y trata de encontrar la raíz de las palabras, obteniendo una normalización más estricta. Un buen ejemplo son la conjugación de los verbos: de *estudiando*, *estudiante* o *estudio* obtenemos *estudi-*. [9]

Frecuencias: TF, IDF

Uno de los datos más importantes a obtener de un texto es la frecuencia de palabras. Esta operación es tan simple como suena: contar cuántas veces aparece cada palabra y anotarlo en una estructura similar a un diccionario. Este término se conoce como *Term*

Frequency o TF. Estos valores suelen representarse en una escala logarítmica, con objeto de que las palabras muy dominantes no eclipsen a las menos frecuentes.

Del campo de teoría de la información [10] conocemos que aquellos términos que aparezcan con una frecuencia muy alta poseerán menos información que aquellos que aparezcan menos. Como vimos en la sección 2.2.1, eliminamos las palabras vacías porque aparecían mucho. Es decir, un artículo como *el* o una preposición como *de* tendrían una frecuencia desproporcionada, cuando en realidad no aportan ninguna información.

De forma similar, el valor *Inverse Document Frequency* [11] trata de abarcar esta frecuencia pero en un conjunto de documentos, añadiendo la inversa de la frecuencia por documento. Esta métrica se utiliza mucho en conjunción con la TF, resultando en la TF-IDF, que trata de medir la relevancia de un término en un conjunto de documentos. Esto resulta en un cálculo tal que así:

$$W(d, t) = TF(d, t) * \log\left(\frac{N}{df(t)}\right) \quad (2.1)$$

donde d es un documento del conjunto de documentos con cardinalidad N , t es el término en concreto y $df(t)$ es el número de documentos que contienen el término t .

Bolsas de palabras

Conociendo el concepto de frecuencias de palabras, una de las aplicaciones directas son las bolsas de palabras, que recogen en una estructura con forma de diccionario cada término y su frecuencia.

De esta forma, tenemos un *ranking* para cada término. Esto se utiliza extensivamente en sistemas de recomendación, en donde una consulta provista por un usuario se compara con la bolsa de palabras del posible conjunto de documentos, y este conjunto va afinándose conforme se van comparando los conjuntos de palabras. El resultado es una búsqueda más refinada que devuelve documentos más relevantes con respecto a la consulta realizada.

2.2.2. Técnicas

En esta sección discutiremos algunas de las técnicas avanzadas más utilizadas en procesamiento y análisis de texto que además utilizaremos en nuestra implementación directa o indirectamente.

Word Embeddings

Esta técnica esencialmente trata de convertir los diferentes términos en vectores de números reales, ya que esto los convierte en objetos matemáticos fáciles de comparar y procesar. Matemáticamente hablando corresponde con una representación de un espacio n -dimensional a un espacio vectorial continuo de menor tamaño, donde n es el número total de términos presentes en todos los documentos.

Esta técnica ha sido estudiada en profundidad en varios proyectos:

- **Word2Vec**: esta técnica trata de representar las palabras como vectores utilizando una red neuronal con dos capas, haciendo uso de una bolsa de palabras continua (CBOW) y el modelo del Skip Gram. [12]
- **GloVe**: acrónimo de *Global Vectors for Word Representation*, es una técnica muy similar a la *Word2Vec*, con la particularidad de estar preentrenada en grandes corpus de texto, basados en Wikipedia y Gigaword. [13]
- **FastText**: es una técnica desarrollada por Facebook. Esta técnica hace uso de la técnica de los n -gramas para su entrenamiento, obteniendo una representación de los términos mucho más granular. [14]
- **Contextualized Word Representations**: esta técnica hace uso del contexto de las palabras para tratar de encontrar una representación y relación entre ellas. Esta técnica basa su funcionamiento en el uso de Long-Short Term Memory, un tipo de red neuronal recurrente muy utilizada en procesamiento de texto, en la que ahondaremos más en profundidad en secciones posteriores de este documento. [15]

Reducción de dimensionalidad

La reducción de dimensionalidad es una técnica que permite proyectar el espacio en el que se hallan nuestros datos en un subespacio de menor dimensionalidad, con objeto de facilitar el cálculo de las propiedades de dichos datos sin tener que utilizar todas sus características. Es común encontrar conjuntos de datos con un número de dimensiones muy alto, que hace inviable su estudio.

Las principales técnicas desarrolladas para reducir la dimensionalidad incluyen:

- **Principal Component Analysis (PCA)**: PCA o análisis de componentes principales trata de encontrar un subespacio latente que represente a los datos encontrando aquellas variables que estén menos relacionadas y que maximicen la varianza, para conservar la mayor cantidad de variabilidad posible. [16]

- **Independent Component Analysis (ICA):** es una técnica similar que trata de expresar los datos con transformaciones lineales. [17]
- **Linear Discriminant Analysis (LDA):** es otro método muy utilizado cuando los datos son de carácter categórico y no tienen una proporción uniforme intraclase. [18]

Toda esta familia de algoritmos resulta muy conveniente para *comprimir* datos de alta dimensionalidad y extraer solo las **características principales** de los mismos. Se suelen usar en etapas de preprocesamiento, donde los datos resultantes se pasan a los algoritmos a entrenar, consiguiendo un mejor resultado y rendimiento en comparación con los datos sin preprocesar.

Clasificación de texto

Por último, abordaremos las principales técnicas para clasificar texto, ámbito importante en nuestro proyecto, así como una breve explicación de las mismas. Al igual que en las secciones anteriores, no es nuestro objetivo estudiarlas en profundidad, pero más bien ofrecer una vista general del panorama en cuanto a esta tecnología con objeto de que el lector se familiarice con los términos.

Los principales algoritmos de clasificación de texto, entre otros, son los siguientes:

- **Boosting y bagging:** boosting y bagging son dos algoritmos basados en lo que se denomina en la literatura como *ensemble learning*. Esta técnica utiliza un gran número de modelos que funcionan muy bien para casos muy específicos pero no generalizan correctamente. La idea es que la respuesta conjunta de todos los modelos nos acerque a la respuesta correcta. Esta decisión puede hacerse mediante votos u otros métodos. [19]
- **Regresión logística:** la regresión logística es uno de los métodos de aprendizaje más simples, junto con la regresión lineal. La regresión logística es una especialización de la regresión lineal, de forma que se utiliza una función logística para predecir categorías discretas, no continuas. [20]
- **Redes neuronales recurrentes:** por último, las redes neuronales recurrentes son una especialización de las redes neuronales en las que un subconjunto de las neuronas reciben su salida como una entrada, generándose ciclos de retroalimentación o *feedback*. Estas redes funcionan especialmente bien con datos con patrones y componentes temporales, características especialmente destacables del lenguaje humano, así como de la música o vídeo. [21]

Existen otras muchas técnicas en clasificación de texto, como *K Nearest Neighbours* [22], *Naïve Bayes* [23], *Support Vector Machines (SVM)* [24], árboles de decisión [25] o *Random Forests* [26], entre muchas otras.

BIBLIOGRAFÍA

- [1] Luis Pereira, Rui Rijo, Catarina Silva, and Ricardo Martinho. Text mining applied to electronic medical records: A literature review. *International Journal of E-Health and Medical Communications (IJEHMC)*, 6:1–18, 07 2015.
- [2] G. Piatetsky-Shapiro. Discovery, analysis, and presentation of strong rules. In *Knowledge Discovery in Databases*, 1991.
- [3] R. Kumar and Rajesh Verma. Classification algorithms for data mining: A survey. *International Journal of Innovations in Engineering and Technology (IJJET)*, 1:7–14, 2012.
- [4] Anil K. Jain, M. N. Murty, and P. Flynn. Data clustering: a review. *ACM Comput. Surv.*, 31:264–323, 1999.
- [5] Jiawei Han, Micheline Kamber, and Jian Pei. 6 - mining frequent patterns, associations, and correlations: Basic concepts and methods. In Jiawei Han, Micheline Kamber, and Jian Pei, editors, *Data Mining (Third Edition)*, The Morgan Kaufmann Series in Data Management Systems, pages 243–278. Morgan Kaufmann, Boston, third edition edition, 2012.
- [6] Kamran Kowsari, K. Meimandi, Mojtaba Heidarysafa, Sanjana Mendu, Laura E. Barnes, and D. Brown. Text classification algorithms: A survey. *Inf.*, 10:150, 2019.
- [7] Umar Farooq, Hasan Mansoor, A. Nongaillard, Y. Ouzrout, and M. Qadir. Negation handling in sentiment analysis at sentence level. *J. Comput.*, 12:470–478, 2017.
- [8] Omar Ali, A. Gegov, Ella Haig, and R. Khusainov. Conventional and structure based sentiment analysis: A survey. *2020 International Joint Conference on Neural Networks (IJCNN)*, pages 1–8, 2020.
- [9] Vimala Balakrishnan and Lloyd-Yemoh Ethel. Stemming and lemmatization: A comparison of retrieval performances. *Lecture Notes on Software Engineering*, 2:262–267, 01 2014.
- [10] Thomas Cover and Joy Thomas. *Elements of Information Theory*, volume 36, pages i – xxiii. 10 2001.
- [11] K. Jones. A statistical interpretation of term specificity and its application in retrieval. *J. Documentation*, 60:493–502, 2004.

- [12] Tomas Mikolov, Kai Chen, G. Corrado, and J. Dean. Efficient estimation of word representations in vector space. In *ICLR*, 2013.
- [13] Jeffrey Pennington, R. Socher, and Christopher D. Manning. Glove: Global vectors for word representation. In *EMNLP*, 2014.
- [14] Piotr Bojanowski, Edouard Grave, Armand Joulin, and Tomas Mikolov. Enriching word vectors with subword information. *Transactions of the Association for Computational Linguistics*, 5:135–146, 2017.
- [15] Oren Melamud, J. Goldberger, and Ido Dagan. context2vec: Learning generic context embedding with bidirectional lstm. In *CoNLL*, 2016.
- [16] I.T. Jolliffe. *Principal Component Analysis*. Springer Verlag, 1986.
- [17] A. Hyvärinen. Topographic independent component analysis. In *Encyclopedia of Computational Neuroscience*, 2014.
- [18] Stan Z. Li and Anil Jain, editors. *LDA (Linear Discriminant Analysis)*, pages 899–899. Springer US, Boston, MA, 2009.
- [19] Eric Bauer and R. Kohavi. An empirical comparison of voting classification algorithms: Bagging, boosting, and variants. *Machine Learning*, 36:105–139, 2004.
- [20] Cox Dr and EJ Snell. The analysis of binary data, 1989.
- [21] Chunting Zhou, Chonglin Sun, Zhiyuan Liu, and Francis C. M. Lau. A c-lstm neural network for text classification. *CoRR*, abs/1511.08630, 2015.
- [22] Xiao-Peng Yu and Xiao-Gao Yu. Novel text classification based on k-nearest neighbor. In *2007 International Conference on Machine Learning and Cybernetics*, volume 6, pages 3425–3430, 2007.
- [23] Eibe Frank and Remco R. Bouckaert. Naive bayes for text classification with unbalanced classes. In *Proceedings of the 10th European Conference on Principles and Practice of Knowledge Discovery in Databases, ECMLPKDD’06*, page 503510, Berlin, Heidelberg, 2006. Springer-Verlag.
- [24] Thorsten Joachims. Text categorization with support vector machines: learning with many relevant features. In Claire Nédellec and Céline Rouveirol, editors, *Proceedings of ECML-98, 10th European Conference on Machine Learning*, number 1398, pages 137–142, Chemnitz, DE, 1998. Springer Verlag, Heidelberg, DE.
- [25] Wan Noormanshah, Puteri Nohuddin, and Zuraini Zainol. Document categorization using decision tree: Preliminary study. *International Journal of Engineering and Technology*, 7:437–440, 12 2018.

- [26] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.